

TEMA 14 · PREVER O SUCESSO DE UM FILME

O PRÓXIMO GRANDE SUCESSO

Um pipeline de Big Data que estima a bilheteria de qualquer filme usando só o que se sabe antes da estreia — e mostra onde a previsão acerta e onde a viralização escapa.

THEOMILLL · JOÃO PEDRO · JOÃO BATISTA · MATHEWS IVO · MENEX100

43.608 FILMES · 5 FONTES · MODELO DE PREDIÇÃO (HISTGRADIENTBOOSTING)

JUNHO / 2026

A PERGUNTA DE UM BILHÃO DE DÓLARES

CUSTA MILHÕES. NINGUÉM SABE SE VAI DAR CERTO.

Um longa-metragem é uma aposta de altíssimo risco feita anos antes de qualquer espectador comprar um ingresso. E se os dados pudessem reduzir essa incerteza?

POR QUE PREVER?

Cada filme é uma aposta de milhões feita anos antes da estreia — em qualquer gênero. Com o histórico de milhares de lançamentos, dá para estimar o risco antes de gastar o primeiro dólar.

43.608

FILMES ANALISADOS

509

RECEITA TOTAL (US\$ BI)

20

GÊNEROS COBERTOS

1874-2018

DÉCADAS DE CINEMA

O QUE CONSTRUÍMOS

- ◆ Um **pipeline de Big Data completo** — das fontes brutas ao destino analítico — sobre 43.608 filmes.
- ◆ Um **modelo preditivo** que estima bilheteria e probabilidade de sucesso usando só o que se sabe antes da estreia.
- ◆ Uma **demonstração em lançamentos de 2026** — de terror a ficção científica — com back-test multigênero contra a bilheteria real.

02 O PIPELINE DE BIG DATA

Arquitetura medalhão · Bronze → Silver → Gold

AS 5 ETAPAS OBRIGATÓRIAS

FONTES	INGESTÃO	TRANSFORMAÇÃO	CARREGAMENTO	DESTINO
5 CSVs brutos The Movies Dataset (Kaggle): metadados, elenco, keywords, links, ratings.	Batch ▶ pandas.read_csv + validação de colunas obrigatórias.	Limpeza + enriquecimento ▶ Parsing JSON, derivação de ROI, lucro, década.	CSV + Parquet ▶ pyarrow grava o dataset gold e 11 tabelas.	Dashboard + modelo ▶ Plotly/Streamlit, notebook e predição.

BRONZE

Ingestão e validação dos 5 arquivos brutos.

SILVER

Limpeza, parsing e cruzamento (diretores, keywords, ratings).

GOLD

Dataset consolidado + 11 tabelas analíticas + modelo.

BRONZE

A FONTE: 45 MIL FILMES

The Movies Dataset (Kaggle) — dados estruturados e semiestruturados (campos JSON de elenco, gênero e keywords). ≈45 mil filmes brutos → 43.608 após a limpeza.

kaggle.com/datasets/rounakbanik/the-movies-dataset

ARQUIVO	CONTEÚDO	PAPEL
01 movies_metadata.csv	orçamento, receita, gênero	núcleo
02 credits.csv	elenco e equipe	diretor
03 keywords.csv	palavras-chave	temas
04 links.csv	ponte MovieLens↔TMDB	join
05 ratings_small.csv	avaliações de usuários	notas

DE BRUTO A VALOR

43.608

FILMES NO DATASET GOLD

11

TABELAS ANALÍTICAS

42.993

FILMES COM DIRETOR EXTRAÍDO

CSV +
Parquet

FORMATOS DE SAÍDA (PYARROW)

- ◆ **Limpeza (Silver):** remoção de IDs inválidos/duplicados, coerção numérica, exclusão de conteúdo adulto, orçamento/receita zero → nulo.
- ◆ **Enriquecimento:** parsing de campos JSON (gênero, elenco, keywords) e derivação de **ROI, lucro, década e flag de franquia**.
- ◆ **Carregamento (Gold):** dataset consolidado + 11 agregações gravados em CSV e Parquet colunar.

STACK OPEN-SOURCE

pandas

Limpeza, merge e agregação.

pyarrow · Parquet

Armazenamento colunar eficiente.

scikit-learn

Modelo de predição (gradient boosting).

Plotly · Streamlit

Dashboard interativo.

matplotlib · seaborn

Gráficos estáticos do pipeline.

Jupyter

Exploração passo a passo.

pytest

Testes do pipeline (2/2 ✓).

GitHub

Versionamento e entrega.

Alternativas pagas para escala: Apache Spark / Databricks, Delta Lake e BI (Power BI / Tableau).

03


O QUE OS DADOS REVELAM

Quatro padrões que definem o sucesso comercial

PADRÃO 1 · ONDE ESTÁ O DINHEIRO

AÇÃO E AVENTURA DOMINAM A RECEITA


Os blockbusters concentram o faturamento total. Mas o jogo muda quando olhamos *eficiência (ROI)* — onde os baixos orçamentos brilham.



PADRÃO 2 · MAIS FILMES, MENOS AMOR

A PRODUÇÃO EXPLODE, A NOTA CAI


A quantidade de filmes dispara década após década, enquanto a nota média dos usuários recua — saturação do mercado.



PADRÃO 3 · SINAIS DE BILHETERIA

ORÇAMENTO E BUZZ MANDAM

A receita tem forte correlação com o nº de votos (0,78) e o orçamento (0,73). Atenção: votos e popularidade só existem depois da estreia.




PADRÃO 4 · O GRANDE ACHADO

DINHEIRO COMPRA
RECEITA — NÃO ROI

*O ROI não se correlaciona com nada (todos ≈ 0). E o pódio de retorno é dos **baixos orçamentos** — de animações clássicas a terror e drama indie: multiplicadores absurdos.*

Sequências e franquias faturam mais — mas a eficiência (ROI) é imprevisível.



04 O MODELO DE SUCESSO

Estimar bilheteria e chance de sucesso usando só o que se sabe antes da estreia

HONESTIDADE PRIMEIRO

*Excluimos tudo que só existe depois da estreia — votos, popularidade, notas. Usar isso seria **vazamento** (espiar o futuro). O modelo prevê com o que se conhece antes — então funciona até em filmes que ainda nem saíram.*

- ◆ **Entram:** orçamento, gênero, **diretor**, duração, franquia, idioma, keywords, sequência/adaptação.
- ◆ **Modelo:** Gradient Boosting (regressão de receita + classificação hit/flop).

0,56

R^2 · RECEITA (LOG) · CV $\pm 0,03$

0,64

ROC-AUC · HIT/FLOP · CV $\pm 0,03$

68%

ACURÁCIA · HOLDOUT (BASE 51%)

49

ERRO MÉDIO US\$ MI · HOLDOUT

Holdout 80/20 + validação cruzada 5-fold · 5.363 filmes com bilheteria reportada · R^2 em escala log · base trivial (classe majoritária) = 51%.

NO NÍVEL DO BASELINE, FIRME NO TEMPO

CONTRA UM MODELO LINEAR (MESMO TESTE)

0,62

 R^2 (LOG) RIDGE → 0,63 HGB

0,72

AUC LOGREG → 0,74 HGB

Na receita, o HGB empata com a regressão linear — o orçamento já carrega quase todo o sinal. O ganho aparece na classificação hit/flop e no ajuste fino de gênero, diretor e franquia.

TESTE DO FUTURO · TREINA < 2010, PREVÊ O RESTO

0,54

 R^2 (LOG) · RECEITA

0,68

AUC · HIT/FLOP


Treinando em 3.732 filmes antigos e prevendo 1.631 posteriores, o desempenho cai pouco — não é só decorar o passado.

Três validações concordam (holdout · CV 5-fold · split temporal) — o resultado é robusto, não sorte de uma divisão.

IMPORTÂNCIA DAS VARIÁVEIS (PERMUTAÇÃO)

O ORÇAMENTO DOMINA TUDO

*Quanto se gasta é, de longe, o sinal pré-estreia mais forte.
Franquia, keywords, diretor e gênero ajustam nas
margens.*



05 PREVENDO LANÇAMENTOS EM CARTAZ

Do blockbuster ao fenômeno de baixo orçamento — vários gêneros, todos antes da estreia

TRÊS LANÇAMENTOS RECENTES

BACKROOMS KANE PARSONS · TERROR · ORÇ. US\$ 10,0 MI RECEITA PREVISTAUS\$ 10,0 mi PROB. DE SUCESSO44% BILHETERIA REALUS\$ 155,0 mi	OBSESSÃO CURRY BARKER · TERROR · ORÇ. US\$ 0,8 MI RECEITA PREVISTAUS\$ 1,4 mi PROB. DE SUCESSO49% BILHETERIA REALUS\$ 171,0 mi	DIA D STEVEN SPIELBERG · FICÇÃO CIENTÍFICA · ORÇ. US\$ 140,0 MI RECEITA PREVISTAUS\$ 235,1 mi PROB. DE SUCESSO53% STATUSrecém-lançado
--	---	--


Escolha do grupo (2 de terror + 1 sci-fi), mas o modelo vale para qualquer gênero. Ele acerta o porte do tentpole do Spielberg — e subestima os fenômenos virais de baixo orçamento, como Obsessão.

BACK-TEST · 13 LANÇAMENTOS, 7 GÊNEROS

CALIBRADO NO MEIO, CEGO NAS CAUDAS

No mainstream ele acerta o porte — *Dune 2*: previsto ~US\$ 751 mi vs real US\$ 715 mi. Mas superestima os flops caros (*Furiosa*, *The Crow*) e **subestima as surpresas baratas** — *Obsessão* e *Anora*, os virais que nenhum dado pré-estreia anuncia.

Nesses 13 extremos: 7/13 acertos de hit/flop · subestimação mediana ~6,3×. Na validação geral (5-fold): 68% · AUC 0,64.



OBSESSÃO · US\$ 750 MIL → US\$ 171 MI · 228×

O MODELO PREVIU US\$ 1,4 MI. A REALIDADE: **US\$ 171 MI.**

*O modelo enxerga orçamento, gênero e diretor — mas não enxerga o que faz um filme barato viralizar. Esse empurrão vem do **buzz antecipado**: visualizações de trailer e menções em redes sociais antes do lançamento, em qualquer gênero. É esse sinal que falta — a fronteira que o Tema 14 aponta.*

CONCLUSÕES & PRÓXIMOS PASSOS

- ◆ **Pipeline completo** entregue e testado (Bronze→Gold, 11 tabelas, 2/2 testes).
- ◆ **Análise:** orçamento é o que mais prevê receita; ROI é imprevisível.
- ◆ **Modelo pré-estreia** (qualquer gênero) acerta o miolo (AUC 0,64), mas erra as caudas virais.
- ◆ **Limitação:** métricas valem só para filmes com bilheteria reportada (viés de sobrevivência).
- ◆ **Futuro:** incorporar **buzz antecipado** (trailer, X, TikTok) — o sinal *pré-estreia* que falta.
- ◆ **Futuro:** elenco, sazonalidade de estreia e gasto de marketing.

Filtros

Gêneros

Choose an option

Décadas

18702010

movies_bigdata - Dashboard AV2

Panorama

Previsão

Prever bilheteria e chance de sucesso

Modelo pré-estreia: usa só o que se sabe ANTES do lançamento (orçamento, gênero, diretor, duração, franquia, keywords). Votos, popularidade e notas ficam de fora por serem sinais pós-estreia — assim dá para prever até filmes que ainda nem saíram.

Orçamento (US\$)

50000000

-

+

Idioma original

en

Diretor

Christopher Nolan

Duração (min)

95

-

+

Ano de lançamento

2020

-

+

☐ Faz parte de coleção/franquia

☐ É sequência

☐ Adaptação de livro

Gênero principal

Action

Qtd. de palavras-chave

2

-

+

Prever

Receita prevista

US\$ 45.8 mi

Chance de hit (≥2x orçamento)

32%

STREAMLIT · AO VIVO

Duas abas: *Panorama* (filtros por gênero/década, gráficos Plotly, ranking de ROI) e *Previsão* — o formulário "teste seu próprio filme".

```
streamlit run
dashboard/streamlit_app.py
```

REPOSITÓRIO GITHUB

README em formato de relatório ABNT + código versionado.

```
/codigo · /notebooks · /dados ·
/documentacao · /apresentacao
```

PIPELINE EM AÇÃO · RESULTADOS CONSOLIDADOS

MOVIES_BIGDATA

24 / 25

OBRIGADO

PERGUNTAS? QUE COMEÇA A SESSÃO.

Da ingestão de ~45 mil filmes brutos à predição do próximo grande sucesso — em qualquer gênero — um pipeline de Big Data de ponta a ponta.