

TEMA 14 · PREVER O SUCESSO DE UM FILME

# O PRÓXIMO GRANDE SUCESSO

*Um pipeline de Big Data que estima a bilheteria de qualquer filme antes da estreia — testado em lançamentos em cartaz, de blockbusters a fenômenos de baixo orçamento.*

THEOMILL · JOÃO PEDRO · JOÃO BATISTA · MATHEWS IVO · MENEX100  
43.608 FILMES · 5 FONTES · MODELO DE PREDIÇÃO PRÉ-LANÇAMENTO

JUNHO / 2026

A PERGUNTA DE UM BILHÃO DE DÓLARES

# CUSTA MILHÕES. NINGUÉM SABE SE VAI DAR CERTO.

*Um longa-metragem é uma aposta de altíssimo risco feita anos antes de qualquer espectador comprar um ingresso. E se os dados pudessem reduzir essa incerteza?*

# POR QUE PREVER?

*Cada filme é uma aposta de milhões feita anos antes da estreia — em qualquer gênero. Com o histórico de milhares de lançamentos, dá para estimar o risco antes de gastar o primeiro dólar.*

**43.608**

FILMES ANALISADOS

**509**

RECEITA TOTAL (US\$ BI)

**20**

GÊNEROS COBERTOS

**1894-2018**

DÉCADAS DE CINEMA



# O QUE CONSTRUÍMOS

- ◆ Um **pipeline de Big Data completo** — das fontes brutas ao destino analítico — sobre 43.608 filmes.
- ◆ Um **modelo preditivo pré-lançamento** que estima bilheteria e probabilidade de sucesso usando só o que se sabe antes da estreia.
- ◆ Uma **demonstração em lançamentos de 2026** — de terror a ficção científica — com back-test multigênero contra a bilheteria real.

# 02 O PIPELINE DE BIG DATA

*Arquitetura medalhão · Bronze → Silver → Gold*

# AS 5 ETAPAS OBRIGATÓRIAS

| FONTES                                                                                            | INGESTÃO                                                               | TRANSFORMAÇÃO                                                                       | CARREGAMENTO                                                         | DESTINO                                                               |
|---------------------------------------------------------------------------------------------------|------------------------------------------------------------------------|-------------------------------------------------------------------------------------|----------------------------------------------------------------------|-----------------------------------------------------------------------|
| <b>5 CSVs brutos</b><br>The Movies Dataset (Kaggle): metadados, elenco, keywords, links, ratings. | <b>Batch</b><br>▶ pandas.read_csv + validação de colunas obrigatórias. | <b>Limpeza + enriquecimento</b><br>▶ Parsing JSON, derivação de ROI, lucro, década. | <b>CSV + Parquet</b><br>▶ pyarrow grava o dataset gold e 11 tabelas. | <b>Dashboard + modelo</b><br>▶ Plotly/Streamlit, notebook e predição. |

**BRONZE**

Ingestão e validação dos 5 arquivos brutos.

**SILVER**

Limpeza, parsing e cruzamento (diretores, keywords, ratings).

**GOLD**

Dataset consolidado + 11 tabelas analíticas + modelo.

BRONZE

# A FONTE: 45 MIL FILMES

*The Movies Dataset (Kaggle) — dados estruturados e semiestruturados (campos JSON de elenco, gênero e keywords). ≈45 mil filmes brutos → 43.608 após a limpeza.*

[kaggle.com/datasets/rounakbanik/the-movies-dataset](https://kaggle.com/datasets/rounakbanik/the-movies-dataset)

| ARQUIVO                | CONTEÚDO                   | PAPEL   |
|------------------------|----------------------------|---------|
| 01 movies_metadata.csv | orçamento, receita, gênero | núcleo  |
| 02 credits.csv         | elenco e equipe            | diretor |
| 03 keywords.csv        | palavras-chave             | temas   |
| 04 links.csv           | ponte MovieLens↔TMDB       | join    |
| 05 ratings_small.csv   | avaliações de usuários     | notas   |



# DE BRUTO A VALOR

43.608

FILMES NO DATASET GOLD

11

TABELAS ANALÍTICAS

42.993

FILMES COM DIRETOR EXTRAÍDO

CSV +  
Parquet

FORMATOS DE SAÍDA (PYARROW)

- ◆ **Limpeza (Silver):** remoção de IDs inválidos/duplicados, coerção numérica, exclusão de conteúdo adulto, orçamento/receita zero → nulo.
- ◆ **Enriquecimento:** parsing de campos JSON (gênero, elenco, keywords) e derivação de **ROI, lucro, década e flag de franquia**.
- ◆ **Carregamento (Gold):** dataset consolidado + 11 agregações gravados em CSV e Parquet colunar.



# STACK OPEN-SOURCE

**pandas**

Limpeza, merge e agregação.

**pyarrow · Parquet**

Armazenamento colunar eficiente.

**scikit-learn**

Modelo de predição (gradient boosting).

**Plotly · Streamlit**

Dashboard interativo.

**matplotlib · seaborn**

Gráficos estáticos do pipeline.

**Jupyter**

Exploração passo a passo.

**pytest**

Testes do pipeline (2/2 ✓).

**GitHub**

Versionamento e entrega.

*Alternativas pagas para escala: Apache Spark / Databricks, Delta Lake e BI (Power BI / Tableau).*

# 03


# O QUE OS DADOS REVELAM

*Quatro padrões que definem o sucesso comercial*

PADRÃO 1 · ONDE ESTÁ O DINHEIRO

# AÇÃO E AVENTURA DOMINAM A RECEITA

Os blockbusters concentram o faturamento total. Mas o jogo muda quando olhamos **eficiência (ROI)** — onde os baixos orçamentos brilham.






PADRÃO 2 · MAIS FILMES, MENOS AMOR

# A PRODUÇÃO EXPLODE, A NOTA CAI


*A quantidade de filmes dispara década após década, enquanto a nota média dos usuários recua — saturação do mercado.*



## PADRÃO 3 · SINAIS DE BILHETERIA

# ORÇAMENTO E BUZZ MANDAM

*A receita tem forte correlação com o n° de votos (0,78) e o orçamento (0,73). Atenção: votos e popularidade só existem depois da estreia.*




PADRÃO 4 · O GRANDE ACHADO

DINHEIRO COMPRA  
RECEITA — NÃO ROI

*O ROI não se correlaciona com nada (todos  $\approx 0$ ). E o pódio de retorno é dos **baixos orçamentos** — de animações clássicas a terror e drama indie: multiplicadores absurdos.*

*Sequências e franquias faturam mais — mas a eficiência (ROI) é imprevisível.*



# 04 O MODELO PRE-LANÇAMENTO

*Prever sucesso usando só o que se sabe antes da estreia*



# HONESTIDADE PRIMEIRO

*Excluimos tudo que só existe depois da estreia — votos, notas, popularidade. Usar isso seria vazamento de dados (ver o futuro).*

- ◆ **Entram:** orçamento, gênero, duração, franquia, idioma, histórico do diretor, keywords.
- ◆ **Modelo:** Gradient Boosting (regressão de receita + classificação hit/flop).

## 0.57

$R^2$  · RECEITA (LOG) ·  $\pm 0.05$

## 0.74

ROC-AUC · HIT/FLOP ·  $\pm 0.01$

## 67%

ACURÁCIA (BASE 51%)

## 49


ERRO MÉDIO (US\$ MI)

*Validação cruzada 5-fold · 5.363 filmes com bilheteria reportada ·  $R^2$  em escala log · base trivial (classe majoritária) = 51%.*

## IMPORTÂNCIA DAS VARIÁVEIS

# O ORÇAMENTO DOMINA TUDO

*Quanto se gasta é, de longe, o sinal pré-lançamento mais forte. Diretor, franquia e keywords ajustam nas margens.*



05

# PREVENDO LANÇAMENTOS EM CARTAZ

*De blockbusters a fenômenos de baixo orçamento — vários gêneros*

# TRÊS LANÇAMENTOS EM CARTAZ

|                                                                                                                                                                                                                                                                     |                                                                                                                                                                                                                                                                   |                                                                                                                                                                                                                                                                          |
|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <div><div>BACKROOMS</div><div>KANE PARSONS · TERROR · ORÇ. US\$ 10.0 MI</div></div> <div><div>RECEITA PREVISTA</div><div>US\$ 9.8 mi</div></div> <div><div>PROB. DE SUCESSO</div><div>41%</div></div> <div><div>BILHETERIA REAL</div><div>US\$ 155.0 mi</div></div> | <div><div>OBSESSÃO</div><div>CURRY BARKER · TERROR · ORÇ. US\$ 0.8 MI</div></div> <div><div>RECEITA PREVISTA</div><div>US\$ 1.4 mi</div></div> <div><div>PROB. DE SUCESSO</div><div>48%</div></div> <div><div>BILHETERIA REAL</div><div>US\$ 171.0 mi</div></div> | <div><div>DIA D</div><div>STEVEN SPIELBERG · FICÇÃO CIENTÍFICA · ORÇ. US\$ 140.0 MI</div></div> <div><div>RECEITA PREVISTA</div><div>US\$ 251.3 mi</div></div> <div><div>PROB. DE SUCESSO</div><div>62%</div></div> <div><div>STATUS</div><div>recém-lançado</div></div> |
|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|

Escolha do grupo (2 de terror + 1 de ficção científica) — mas o modelo vale para qualquer gênero. O back-test completo cobre 7 gêneros.




BACK-TEST · 13 LANÇAMENTOS, 7 GÊNEROS

CALIBRADO NO MEIO,  
CEGO NAS CAUDAS

No mainstream ele acerta — *Dune 2*: previsto ~US\$ 623 mi vs real US\$ 715 mi. Mas superestima os flops caros (*Furiosa*, *The Crow*) e **subestima as surpresas baratas** de qualquer gênero — *Anora* (drama) e *Obsessão* (~120×).

Nesses 13 extremos: 6/13 acertos · subestimação mediana ~4,9×. Na validação cruzada (5-fold): 67% · AUC 0,74.



OBSESSÃO · US\$ 750 MIL → US\$ 171 MI · 228×

# O MODELO PREVIU US\$ 1,4 MI. A REALIDADE: **US\$ 171 MI.**

*É não é só terror: Anora (drama, US\$ 6 mi → US\$ 59 mi) também escapou. O sucesso explosivo de baixo orçamento — em qualquer gênero — vive no **buzz social** (engajamento pré-estreia), o sinal que falta. É a fronteira que o Tema 14 aponta.*



# CONCLUSÕES & PRÓXIMOS PASSOS

- ◆ **Pipeline completo** entregue e testado (Bronze→Gold, 11 tabelas, 2/2 testes).
- ◆ **Análise:** orçamento e buzz preveem receita; ROI é imprevisível.
- ◆ **Modelo geral** (qualquer gênero) acerta o miolo (AUC 0,74), mas erra as caudas.
- ◆ **Limitação:** métricas valem só para filmes com bilheteria reportada (viés de sobrevivência).
- ◆ **Futuro:** incorporar **buzz de redes sociais** (X, Reddit, YouTube).
- ◆ **Futuro:** elenco, sazonalidade de estreia e gasto de marketing.

Filtros

Gêneros

Choose an option

Décadas

1870

2010

movies\_bigdata — Dashboard AV2

Pipeline de Big Data + modelo de predição de sucesso pré-lançamento · Tema 14

Panorama dos dados

Predição de lançamentos

Modelo de predição de sucesso (pré-lançamento)

R<sup>2</sup> · receita (log)

0.57

ROC-AUC · hit/flop

0.74

Acurácia

67%

Erro médio

US\$ 49 mi

Sem vazamento de dados: votos, notas e popularidade (pós-estreia) ficam de fora. Features pré-lançamento: orçamento, gênero, diretor, franquia, duração, idioma, keywords.

Back-test — lançamentos recentes (vários gêneros)

| Filme          | Diretor          | Ano   | Orçamento     | Receita prevista | Prob. sucesso | Veredito         | Bilheteria real | ROI previsto (x) | ROI real (x) |
|----------------|------------------|-------|---------------|------------------|---------------|------------------|-----------------|------------------|--------------|
| Obsessão       | Curry Barker     | 2,026 | US\$ 0.8 mi   | US\$ 1.4 mi      | 48%           | ALTO RISCO       | US\$ 171.0 mi   | 1.9              | 228.0        |
| Backrooms      | Kane Parsons     | 2,026 | US\$ 10.0 mi  | US\$ 9.8 mi      | 41%           | ALTO RISCO       | US\$ 155.0 mi   | 1                | 15.5         |
| Dia D (sci-fi) | Steven Spielberg | 2,026 | US\$ 140.0 mi | US\$ 251.3 mi    | 62%           | PROVÁVEL SUCESSO | —               | 1.8              | —            |
| Terrifier 3    | Damien Leone     | 2,024 | US\$ 2.0 mi   | US\$ 10.4 mi     | 85%           | PROVÁVEL SUCESSO | US\$ 90.3 mi    | 5.2              | 45.2         |
| Longlegs       | Osgood Perkins   | 2,024 | US\$ 10.0 mi  | US\$ 10.9 mi     | 45%           | ALTO RISCO       | US\$ 128.0 mi   | 1.1              | 12.8         |
| Anora          | Sean Baker       | 2,024 | US\$ 6.0 mi   | US\$ 3.5 mi      | 23%           | ALTO RISCO       | US\$ 59.3 mi    | 0.6              | 9.9          |
| Inside Out 2   | Kelsey Mann      | 2,024 | US\$ 200.0 mi | US\$ 772.4 mi    | 92%           | PROVÁVEL SUCESSO | US\$ 1698.9 mi  | 3.9              | 8.5          |
| Wicked         | Jon M. Chu       | 2,024 | US\$ 150.0 mi | US\$ 349.4 mi    | 56%           | PROVÁVEL SUCESSO | US\$ 765.1 mi   | 2.3              | 5.1          |
| Smile 2        | Parker Finn      | 2,024 | US\$ 28.0 mi  | US\$ 81.7 mi     | 84%           | PROVÁVEL SUCESSO | US\$ 138.1 mi   | 2.9              | 4.9          |
| The Substance  | Coralie Fargeat  | 2,024 | US\$ 18.0 mi  | US\$ 15.7 mi     | 30%           | ALTO RISCO       | US\$ 77.3 mi    | 0.9              | 4.3          |

Previsto vs. real (escala log) — pontos acima da linha = subestimados

PIPELINE EM AÇÃO · RESULTADOS CONSOLIDADOS

MOVIES\_BIGDATA

STREAMLIT · AO VIVO

*Filtros por gênero/década, gráficos Plotly, ranking de ROI e o formulário "teste seu próprio filme".*

```
streamlit run
dashboard/streamlit_app.py
```

REPOSITÓRIO GITHUB

*README em formato de relatório ABNT + código versionado.*

```
/codigo · /notebooks · /dados ·
/documentacao · /apresentacao
```

23 / 24



OBRIGADO

# PERGUNTAS? QUE COMEÇA A SESSÃO.

*Da ingestão de ~45 mil filmes brutos à predição do próximo grande sucesso — em qualquer gênero — um pipeline de Big Data de ponta a ponta.*