

TEMA 14 · PREVER O SUCESSO DE UM FILME

O PRÓXIMO GRANDE SUCESSO

Um pipeline de Big Data que estima a bilheteria de qualquer filme a partir dos seus atributos e do buzz — e expõe por que prever antes da estreia ainda é a fronteira.

THEOMILLL · JOÃO PEDRO · JOÃO BATISTA · MATHEWS IVO · MENEX100

43.608 FILMES · 5 FONTES · MODELO DE PREDIÇÃO (HISTGRADIENTBOOSTING)

JUNHO / 2026

A PERGUNTA DE UM BILHÃO DE DÓLARES

CUSTA MILHÕES. NINGUÉM SABE SE VAI DAR CERTO.

Um longa-metragem é uma aposta de altíssimo risco feita anos antes de qualquer espectador comprar um ingresso. E se os dados pudessem reduzir essa incerteza?

POR QUE PREVER?

Cada filme é uma aposta de milhões feita anos antes da estreia — em qualquer gênero. Com o histórico de milhares de lançamentos, dá para estimar o risco antes de gastar o primeiro dólar.

43.608

FILMES ANALISADOS

509

RECEITA TOTAL (US\$ BI)

20

GÊNEROS COBERTOS

1874-2018

DÉCADAS DE CINEMA

O QUE CONSTRUÍMOS

- ◆ Um **pipeline de Big Data completo** — das fontes brutas ao destino analítico — sobre 43.608 filmes.
- ◆ Um **modelo preditivo** que estima bilheteria e probabilidade de sucesso a partir dos atributos do filme e dos sinais de engajamento.
- ◆ Uma **demonstração em lançamentos de 2026** — de terror a ficção científica — com back-test multigênero contra a bilheteria real.

02 O PIPELINE DE BIG DATA

Arquitetura medalhão · Bronze → Silver → Gold

AS 5 ETAPAS OBRIGATÓRIAS

FONTES	INGESTÃO	TRANSFORMAÇÃO	CARREGAMENTO	DESTINO
5 CSVs brutos The Movies Dataset (Kaggle): metadados, elenco, keywords, links, ratings.	Batch ▶ pandas.read_csv + validação de colunas obrigatórias.	Limpeza + enriquecimento ▶ Parsing JSON, derivação de ROI, lucro, década.	CSV + Parquet ▶ pyarrow grava o dataset gold e 11 tabelas.	Dashboard + modelo ▶ Plotly/Streamlit, notebook e predição.

BRONZE

Ingestão e validação dos 5 arquivos brutos.

SILVER

Limpeza, parsing e cruzamento (diretores, keywords, ratings).

GOLD

Dataset consolidado + 11 tabelas analíticas + modelo.

BRONZE

A FONTE: 45 MIL FILMES

The Movies Dataset (Kaggle) — dados estruturados e semiestruturados (campos JSON de elenco, gênero e keywords). ≈45 mil filmes brutos → 43.608 após a limpeza.

kaggle.com/datasets/rounakbanik/the-movies-dataset

ARQUIVO	CONTEÚDO	PAPEL
01 movies_metadata.csv	orçamento, receita, gênero	núcleo
02 credits.csv	elenco e equipe	diretor
03 keywords.csv	palavras-chave	temas
04 links.csv	ponte MovieLens↔TMDB	join
05 ratings_small.csv	avaliações de usuários	notas

DE BRUTO A VALOR

43.608

FILMES NO DATASET GOLD

11

TABELAS ANALÍTICAS

42.993

FILMES COM DIRETOR EXTRAÍDO

CSV +
Parquet

FORMATOS DE SAÍDA (PYARROW)

- ◆ **Limpeza (Silver):** remoção de IDs inválidos/duplicados, coerção numérica, exclusão de conteúdo adulto, orçamento/receita zero → nulo.
- ◆ **Enriquecimento:** parsing de campos JSON (gênero, elenco, keywords) e derivação de **ROI, lucro, década e flag de franquia**.
- ◆ **Carregamento (Gold):** dataset consolidado + 11 agregações gravados em CSV e Parquet colunar.

STACK OPEN-SOURCE

pandas

Limpeza, merge e agregação.

pyarrow · Parquet

Armazenamento colunar eficiente.

scikit-learn

Modelo de predição (gradient boosting).

Plotly · Streamlit

Dashboard interativo.

matplotlib · seaborn

Gráficos estáticos do pipeline.

Jupyter

Exploração passo a passo.

pytest

Testes do pipeline (2/2 ✓).

GitHub

Versionamento e entrega.

Alternativas pagas para escala: Apache Spark / Databricks, Delta Lake e BI (Power BI / Tableau).

03


O QUE OS DADOS REVELAM

Quatro padrões que definem o sucesso comercial

PADRÃO 1 · ONDE ESTÁ O DINHEIRO

AÇÃO E AVENTURA DOMINAM A RECEITA


Os *blockbusters* concentram o faturamento total. Mas o jogo muda quando olhamos *eficiência (ROI)* — onde os baixos orçamentos brilham.



PADRÃO 2 · MAIS FILMES, MENOS AMOR

A PRODUÇÃO EXPLODE, A NOTA CAI


A quantidade de filmes dispara década após década, enquanto a nota média dos usuários recua — saturação do mercado.



PADRÃO 3 · SINAIS DE BILHETERIA

ORÇAMENTO E BUZZ MANDAM

A receita tem forte correlação com o nº de votos (0,78) e o orçamento (0,73). Atenção: votos e popularidade só existem depois da estreia.




PADRÃO 4 · O GRANDE ACHADO

DINHEIRO COMPRA
RECEITA — NÃO ROI

*O ROI não se correlaciona com nada (todos ≈ 0). E o pódio de retorno é dos **baixos orçamentos** — de animações clássicas a terror e drama indie: multiplicadores absurdos.*

Sequências e franquias faturam mais — mas a eficiência (ROI) é imprevisível.



04

O MODELO DE SUCESSO

Estimar bilheteria e chance de sucesso a partir dos atributos do filme e dos sinais de engajamento (buzz)

HONESTIDADE PRIMEIRO

*Separamos alvo de sinal: receita, lucro e ROI ficam de fora (seriam **vazamento** direto). Os sinais de engajamento — votos, popularidade, notas — entram, mas avisamos: só amadurecem depois da estreia.*

- ◆ **Entram:** orçamento, gênero, duração, franquia, idioma, keywords + **engajamento** (votos, popularidade, notas).
- ◆ **Modelo:** Gradient Boosting (regressão de receita + classificação hit/flop).

0,65

R^2 · RECEITA (LOG) · CV $\pm 0,05$

0,80

ROC-AUC · HIT/FLOP · CV $\pm 0,03$

76%

ACURÁCIA · HOLDOUT (BASE 51%)

39

ERRO MÉDIO US\$ MI · HOLDOUT

Holdout 80/20 + validação cruzada 5-fold · 5.363 filmes com bilheteria reportada · R^2 em escala log · base trivial (classe majoritária) = 51%.

BATE O BASELINE — E SOBREVIVE AO TEMPO

CONTRA UM MODELO LINEAR (MESMO TESTE)

0,37 R^2 (LOG) RIDGE → 0,72 HGB**0,83**

AUC LOGREG → 0,85 HGB

O Gradient Boosting supera a regressão linear — o ganho vem de capturar relações não-lineares entre orçamento, buzz e gênero.

TESTE DO FUTURO · TREINA < 2010, PREVÊ O RESTO

0,62 R^2 (LOG) · RECEITA**0,78**

AUC · HIT/FLOP


Treinando em 3.732 filmes antigos e prevendo 1.631 posteriores, o desempenho cai pouco — não é só decorar o passado.

Três validações concordam (holdout · CV 5-fold · split temporal) — o resultado é robusto, não sorte de uma divisão.

IMPORTÂNCIA DAS VARIÁVEIS (PERMUTAÇÃO)

ORÇAMENTO E VOTOS EMPATAM

Nº de votos disputa o topo com o orçamento — quase empatados. O detalhe incômodo: votos só existem depois da estreia. O modelo se apoia, em boa parte, em buzz pós-lançamento.



05

A FRONTEIRA PRÉ-ESTREIA

O que acontece com lançamentos recentes quando tiramos o buzz que o modelo mais usa

TRÊS LANÇAMENTOS RECENTES

BACKROOMS KANE PARSONS · TERROR · ORÇ. US\$ 10,0 MI RECEITA PREVISTA US\$ 0,9 mi PROB. DE SUCESSO 9% BILHETERIA REAL US\$ 155,0 mi	OBSESSÃO CURRY BARKER · TERROR · ORÇ. US\$ 0,8 MI RECEITA PREVISTA US\$ 0,6 mi PROB. DE SUCESSO 24% BILHETERIA REAL US\$ 171,0 mi	DIA D STEVEN SPIELBERG · FICÇÃO CIENTÍFICA · ORÇ. US\$ 140,0 MI RECEITA PREVISTA US\$ 7,1 mi PROB. DE SUCESSO 5% STATUS recém-lançado
--	---	---


Sem o buzz (que o modelo mais usa), a previsão antes da estreia desaba: o modelo crava "alto risco" nos três — Backrooms, previsto **US\$ 0,9 mi**, fez US\$ 155 mi. Ele aposta em fracasso justamente nos maiores sucessos.

PRÉ-ESTREIA (BUZZ MEDIANO) · 13
LANÇAMENTOS, 7 GÊNEROS

TIRE O BUZZ E O MODELO CEGA

Os mesmos três e mais dez lançamentos (13 ao todo). Com os votos preenchidos pela mediana, quase tudo despenca abaixo da diagonal: o modelo subestima de forma sistemática. Backrooms, Obsessão, Nosferatu — previstos em poucos milhões, arrecadaram centenas. O sinal que ele aprendeu a usar **não existe antes da estreia**.

O mesmo modelo, no seu teste próprio (com buzz real), acerta 76% · AUC 0,80. A queda aqui não é do modelo — é da informação que falta no pré-estreia.



OBSESSÃO · US\$ 750 MIL → US\$ 171 MI · 228×

PRÉ-ESTREIA, O MODELO PREVIOU
US\$ 0,6 MI.
A REALIDADE: **US\$ 171 MI.**

*O modelo se apoia em votos e popularidade — mas esses sinais só chegam depois da estreia. O que antecipa o sucesso explosivo de baixo orçamento, em qualquer gênero, é o **buzz antecipado**: visualizações de trailer e menções em redes sociais antes do lançamento. É esse sinal que falta — a fronteira que o Tema 14 aponta.*

CONCLUSÕES & PRÓXIMOS PASSOS

- ◆ **Pipeline completo** entregue e testado (Bronze→Gold, 11 tabelas, 2/2 testes).
- ◆ **Análise:** orçamento e buzz preveem receita; ROI é imprevisível.
- ◆ **Modelo geral** (qualquer gênero) acerta o miolo (AUC 0,80), mas depende de buzz pós-estreia.
- ◆ **Limitação:** métricas valem só para filmes com bilheteria reportada (viés de sobrevivência).
- ◆ **Futuro:** incorporar **buzz antecipado** (trailer, X, TikTok) — o sinal *pré-estreia* que falta.
- ◆ **Futuro:** elenco, sazonalidade de estreia e gasto de marketing.

Filtros

Gêneros

Choose an option

Décadas

18702010

movies_bigdata - Dashboard AV2

PanoramaPrevisão

Prever bilheteria e chance de sucesso

vote_count, popularidade e notas só existem após o lançamento; os campos de engajamento vêm preenchidos com a mediana da base. O modelo estima a bilheteria com buzz pós-lançamento, não é uma previsão pura pré-lançamento.

Orçamento (US\$)

50000000

-+

Idioma original

en

☐ Faz parte de coleção/franquia

Duração (min)

95

-+

Ano de lançamento

2020

-+

Gênero principal

Action

Qtd. de palavras-chave

2

-+

Votos esperados (TMDB)

10

-+

Popularidade esperada

1.19

-+

Prever

Receita prevista

US\$ 1.4 mi

Chance de hit (≥2x orçamento)

5%

PIPELINE EM AÇÃO · RESULTADOS CONSOLIDADOS

MOVIES_BIGDATA

24 / 25

STREAMLIT · AO VIVO

Duas abas: *Panorama* (filtros por gênero/década, gráficos Plotly, ranking de ROI) e *Previsão* — o formulário "teste seu próprio filme".

```
streamlit run
dashboard/streamlit_app.py
```

REPOSITÓRIO GITHUB

README em formato de relatório ABNT + código versionado.

```
/codigo · /notebooks · /dados ·
/documentacao · /apresentacao
```

OBRIGADO

PERGUNTAS? QUE COMEÇA A SESSÃO.

Da ingestão de ~45 mil filmes brutos à predição do próximo grande sucesso — em qualquer gênero — um pipeline de Big Data de ponta a ponta.